Apache Flink Apache Paimon

Apache Paimon 流式数据湖

V 0.4 与后续展望

李劲松（之信）
阿里云开源大数据表存储团队负责人、阿里巴巴高级技术专家，
Apache Flink PMC，Paimon PPMC

Apache Flink Apache Paimon

CONTENT

目录 >>

01 /
湖存储上的难点

02 /
深入 Apache Paimon 0.4

03 /
社区应用实践

04 /
未来规划

一、湖存储上的难点

数据湖新场景

Apache Flink Apache Paimon

- 实时数据入湖

  实时更新来自数据库的 CDC 数据，

  能被多种引擎尽快分析

- 实时字段打宽

  实时打宽维表的字段，

  提供给下游查询及流读

- 实时数据流读

  提供消息队列体验的流读，

  并能根据主键生成 Changelog

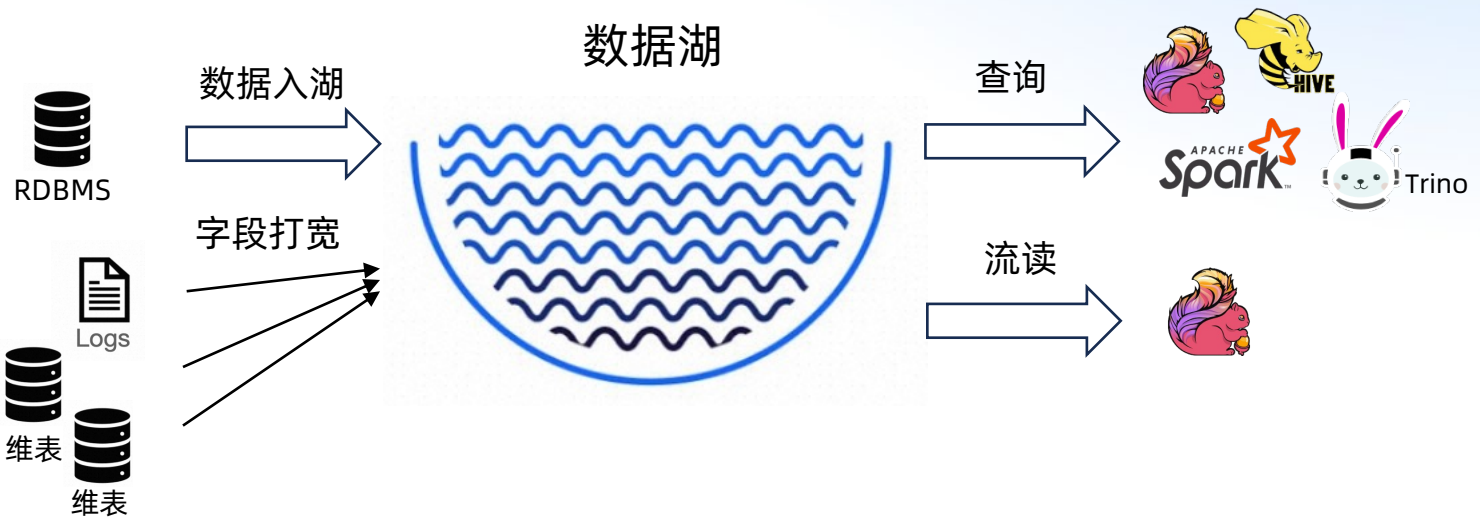

入湖的痛点

- 资源消耗与实时性

  更新吞吐差，资源消耗巨大

  COW 更新差，MOR 查询差，难以选择

  反压、反压、还是反压

- 数据湖需管理的事情多

  管理 compaction

  清理历史小文件

  清理过期分区

- Schema Evolution

  上游加列，湖存储怎么办？

  重启同步作业？

  一堆小表耗资源且耗精力

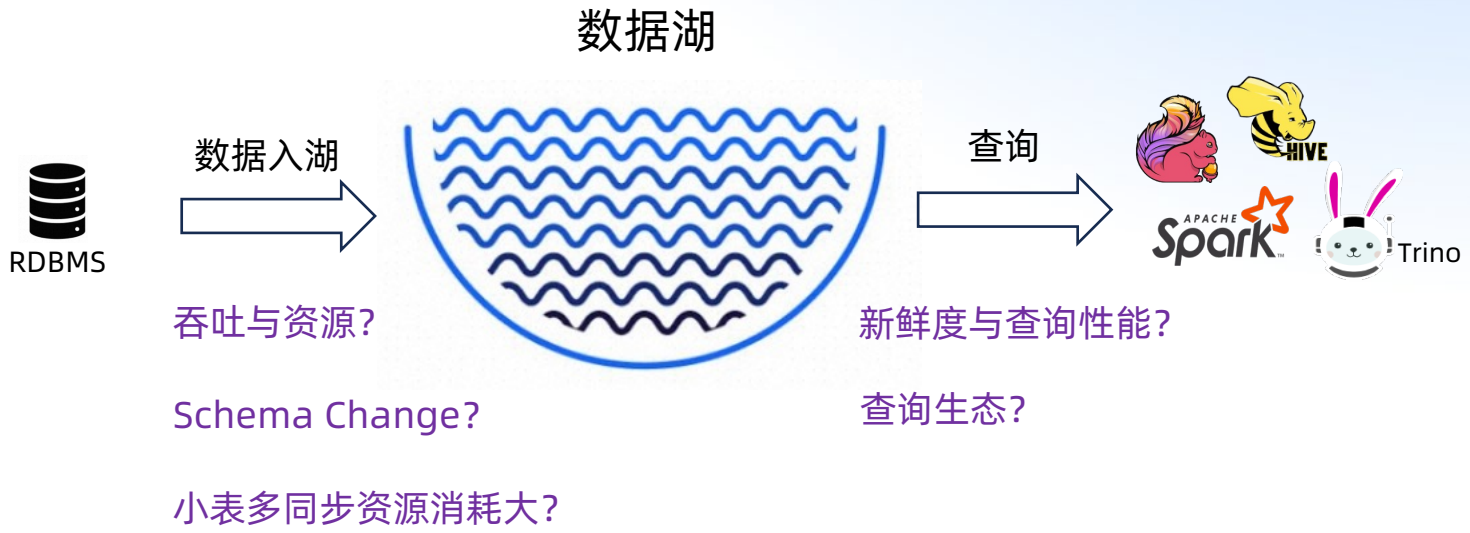

打宽表的痛点

Apache Flink Apache Paimon

- 资源消耗与实时性

  同样重要

- 输入多样性

  CDC 输入

  输入可能是乱序的

- 读取

  批读支持列裁剪

  流读?

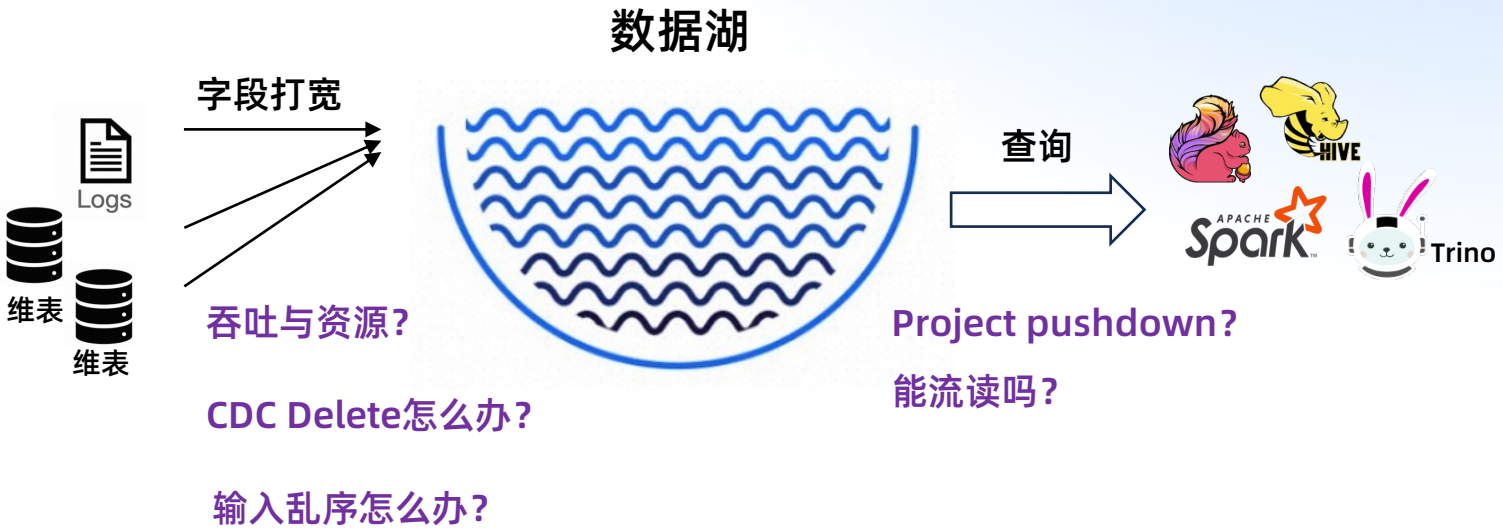

流读的痛点

- 全增量一体流读

  先读全量再接增量，完整的流

- Changelog 生成

  有些场景要低成本

  有些场景要低时延

- 痛点：FileNotFound

  数据湖文件清理和流读的矛盾

- Lookup Join

  支持 Flink 的 Lookup Join

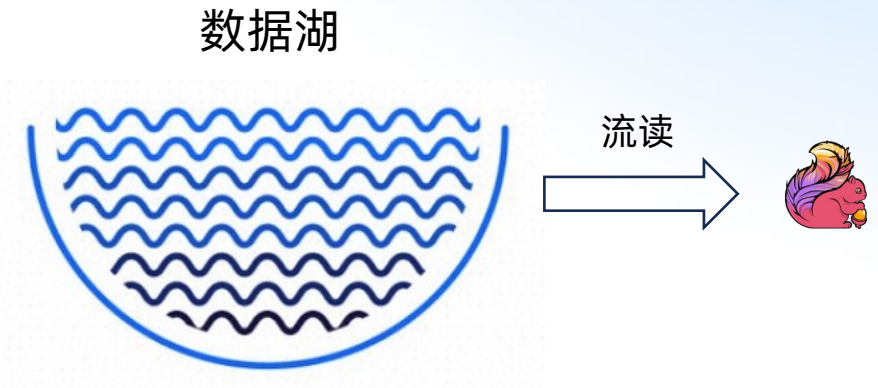

数据湖流读，建议 1分钟+延时的场景

Apache Flink Apache Paimon

Apache Paimon：一个专门为 CDC 处理、流计算而生的数据湖。
希望带来你舒服、自动的湖上流处理体验。

Apache Paimon is a streaming data lake platform that supports high-speed data ingestion, change data tracking and efficient real-time analytics.

二、深入 Apache Paimon 0.4

Paimon 架构

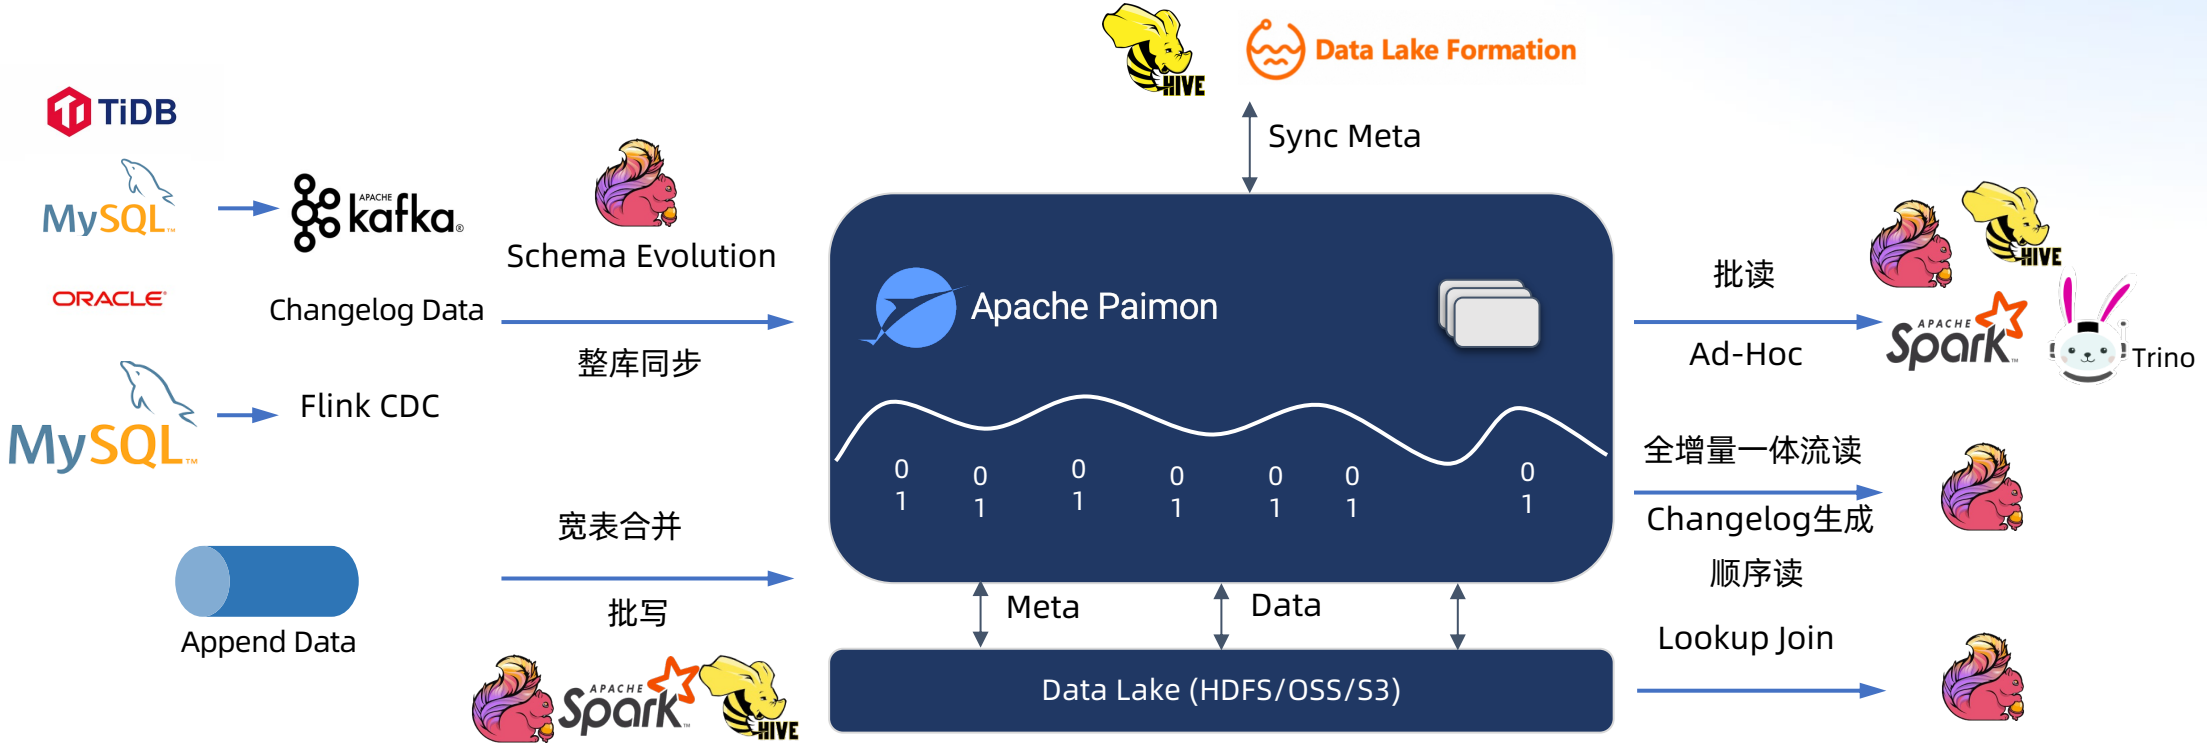
Apache Flink
Apache Paimon
Data Lake Formation
Sync Meta
TiDB
MySQL
kafka
ORACLE
MySQL
Schema Evolution
Changelog Data
整库同步
Flink CDC
Apache Paimon
Meta
Data
Data Lake (HDFS/OSS/S3)
批读
Ad-Hoc
Trino
全增量一体流读
Changelog生成
顺序读
Lookup Join
宽表合并
批写
Append Data

Paimon: 理解写入与查询

- **写入**：写入发生在 Flink Sink 中，当检查点到达时，它会对内存中的数据进行排序，并将记录刷新到 Level0 文件中。
- **压缩**：默认情况下，Flink Sink 中也会发生异步压缩，当然，您可以启动单独的压缩作业。由于 LSM 的设计，合并是局部的，这可以有效地减少写放大。
- **清理**：写入作业默认会清理过期的快照，有效的清理可以减少DFS上大量的文件，而且你还可以配置分区的清理策略。
- **读取**：发生在新启动的作业中，您可以查询在文件系统上提交的快照。该查询将合并多个 Level 的 LSM，这可能会有一些开销，但不会很慢。

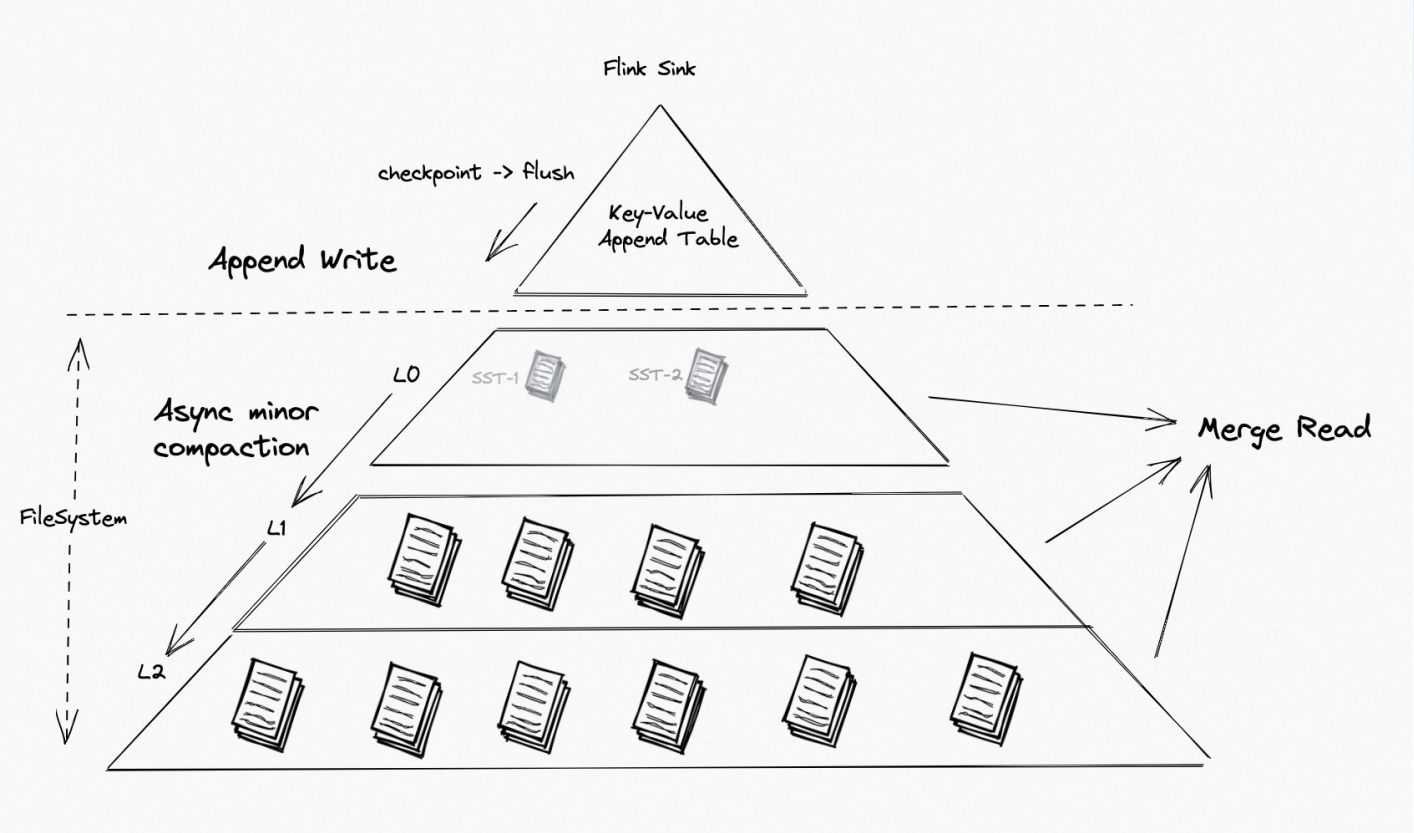

Append 写 (吞吐大)、局部压缩 (消耗低)、自动清理 (全自动)、有序合并 (不会很慢)

Paimon: 入湖带来的收益

Apache Flink Apache Paimon

来自同程旅行的生产实践 (对比原有 Hudi 表):

#1

资源节省:

流计算任务资源节省30%

实时ODS存储资源节省40%

#2

性能效率

任务写入性能（全量+增量）提升3倍左右

部分查询性能提升7倍

Paimon: CDC 入湖

Apache Flink Apache Paimon

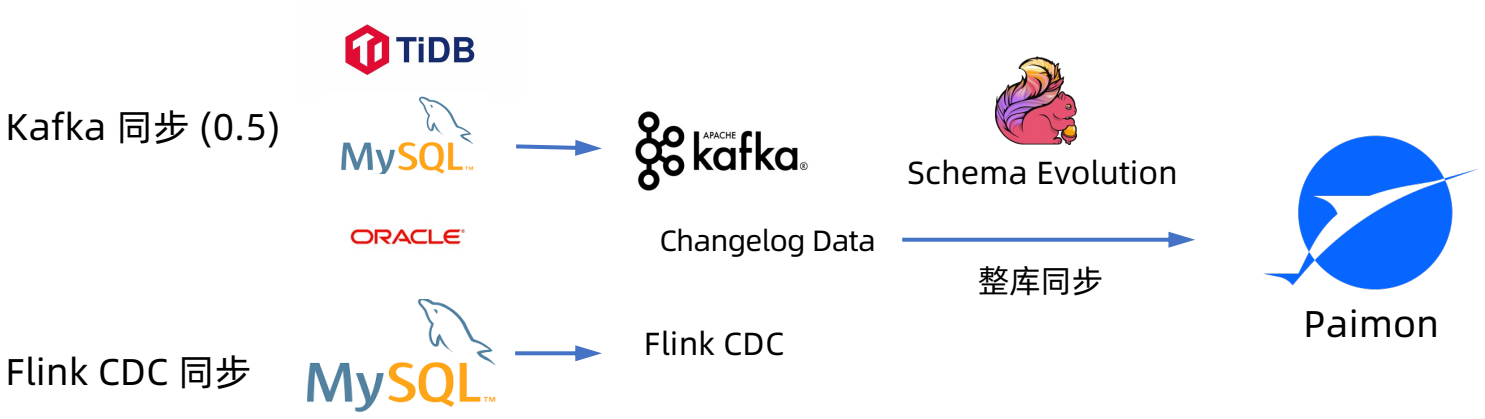

一键同步入湖

```
<FLINK_HOME>/bin/flink run \
    /path/to/paimon-flink-action-0.5-SNAPSHOT.jar \
    mysql-sync-database \
    --warehouse hdfs:///path/to/warehouse \
    --database test_db \
    --mysql-conf hostname=127.0.0.1 \
    --mysql-conf username=root \
    --mysql-conf password=123456 \
    --mysql-conf database-name=source_db \
    --catalog-conf metastore=hive \
    --catalog-conf uri=thrift://hive-metastore:9083 \
    --table-conf bucket=4 \
    --table-conf changelog-producer=input \
    --table-conf sink.parallelism=4
```

表同步		Paimon CDC
表结构变更同步	增加列	✅
	删除列	✅ (忽略)
	类型变更	✅ (0.4 隐式转换，0.5 强转换)
	重命名列	✅ 添加新一列
新增计算列		✅
定义分区列		✅
定义主键		✅
分库分表同步		✅

整库同步	Paimon CDC
INCLUDING/EXCLUDING	✅
表名前后缀	✅
自动跳过失败的表	✅
动态新增表	✅ (0.5)

CDC DataStream API：编写 Schema 同步的流作业

Paimon: 部分更新

Apache Flink Apache Paimon

- 流读：支持流读合并后的数据。
- 查询：支持列裁剪。
- 乱序：支持定义 Sequence Field 处理乱序。

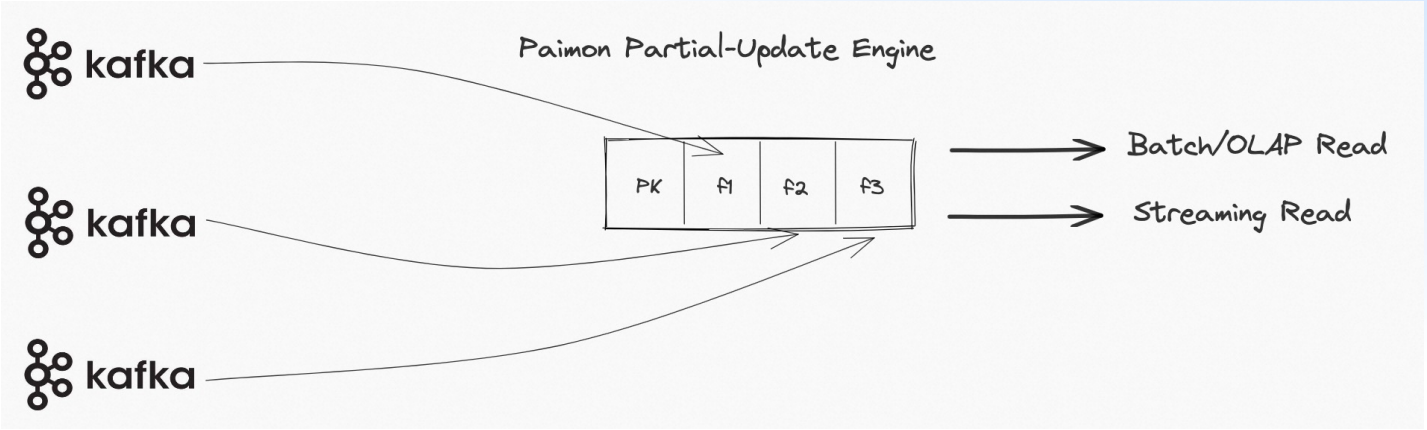

0.5 引入 Sequence Group 概念：
- 每个流定义自己的序列组应对多流乱序
- 真正的部分更新，而不仅仅是non-null更新

```sql
CREATE TABLE T (
    k INT,
    a INT,
    b INT,
    g_1 INT,
    c INT,
    d INT,
    g_2 INT,
    PRIMARY KEY (k) NOT ENFORCED
) WITH (
    'merge-engine'='partial-update',
    'fields.g_1.sequence-group'='a,b',
    'fields.g_2.sequence-group'='c,d'
);

INSERT INTO T VALUES (1, 1, 1, 1, 1, 1, 1);

-- g_2 is null, c, d should not be updated
INSERT INTO T VALUES (1, 2, 2, 2, 2, 2, CAST(NULL AS INT));
```

Paimon: 流读增强

- 流读：支持流读原始数据。(changelog-producer=input)
- 变更日志：支持生成变更日志，Lookup 模式 cp 可见 (1-3分钟时延)，Full-compaction 模式延迟可见 (3-10分钟时延)
- Consumer-ID：支持 Consumer-ID，支持流读无状态重启，也解决流读恢复时的 FileNotFound 问题。

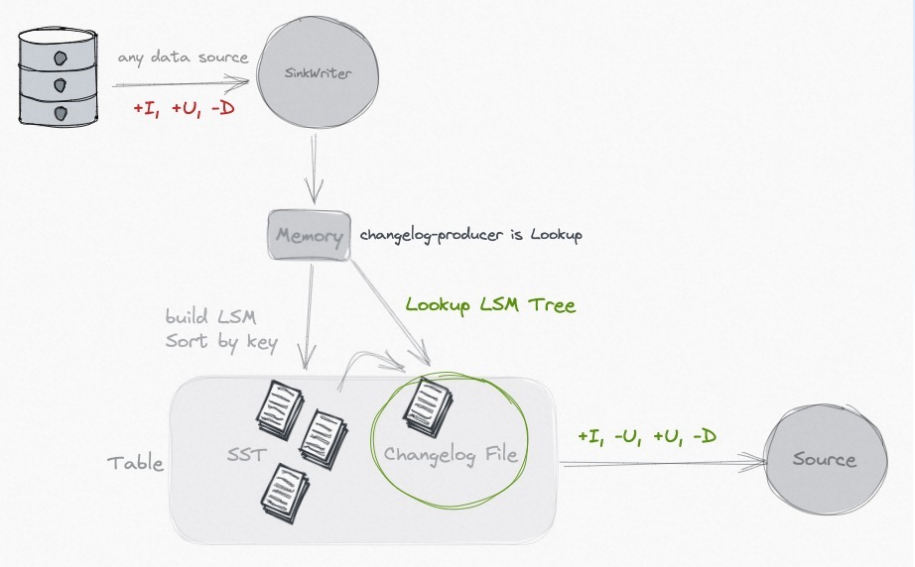

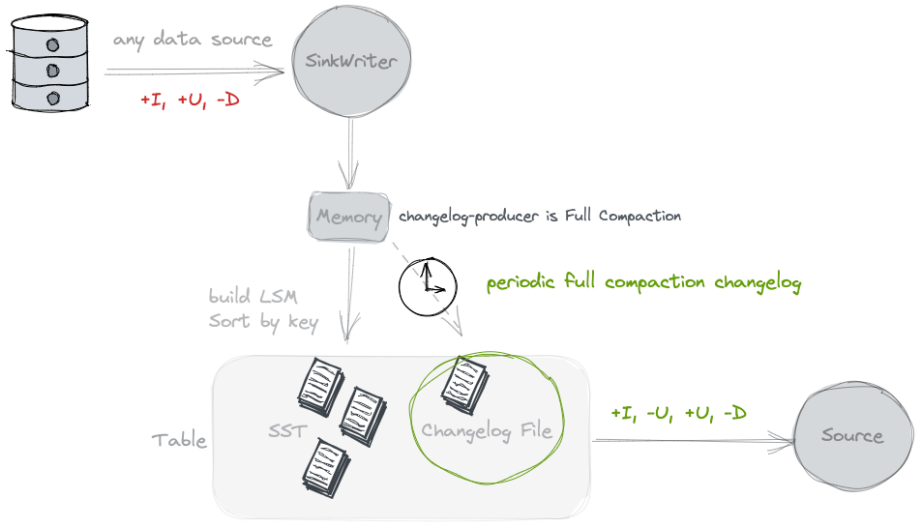

Paimon: 生态

Apache Flink Apache Paimon

Engine	Version	Batch Read	Batch Write	Create Table	Alter Table	Streaming Write	Streaming Read	Batch Overwrite
Flink	1.14 - 1.17	✅	✅	✅	✅(1.17+)	✅	✅	✅
Spark	3.1 - 3.4	✅	✅	✅	✅	❌	❌	❌
Hive	2.1 - 3.1	✅	✅	✅	❌	❌	❌	❌
Spark	2.4	✅	❌	❌	❌	❌	❌	❌
Trino	358 - 400	✅	❌	✅	✅	❌	❌	❌
Presto	0.236 - 0.279	✅	❌	❌	❌	❌	❌	❌

StarRocks

DORIS

Apache SeaTunnel

即将发布！

Hologres

MaxCompute

Arctic

在路上！

三、社区应用实践

开源社区

Apache Flink

Apache Paimon

阿里云

ByteDance 字节跳动

同程旅行

bilibili

中原银行 ZHONGYUAN BANK

miHoYo TECH OTAKUS SAVE THE WORLD

尘锋信息 dustess.com

汽车之家 autohome.com.cn

海兰寰宇 Highland-Huanyu

巴别时代 BABELTIME

阿里云

阿里云计算平台

- 数据湖一号位，计算全集成
- 替代 Hudi 成为实时入湖首选

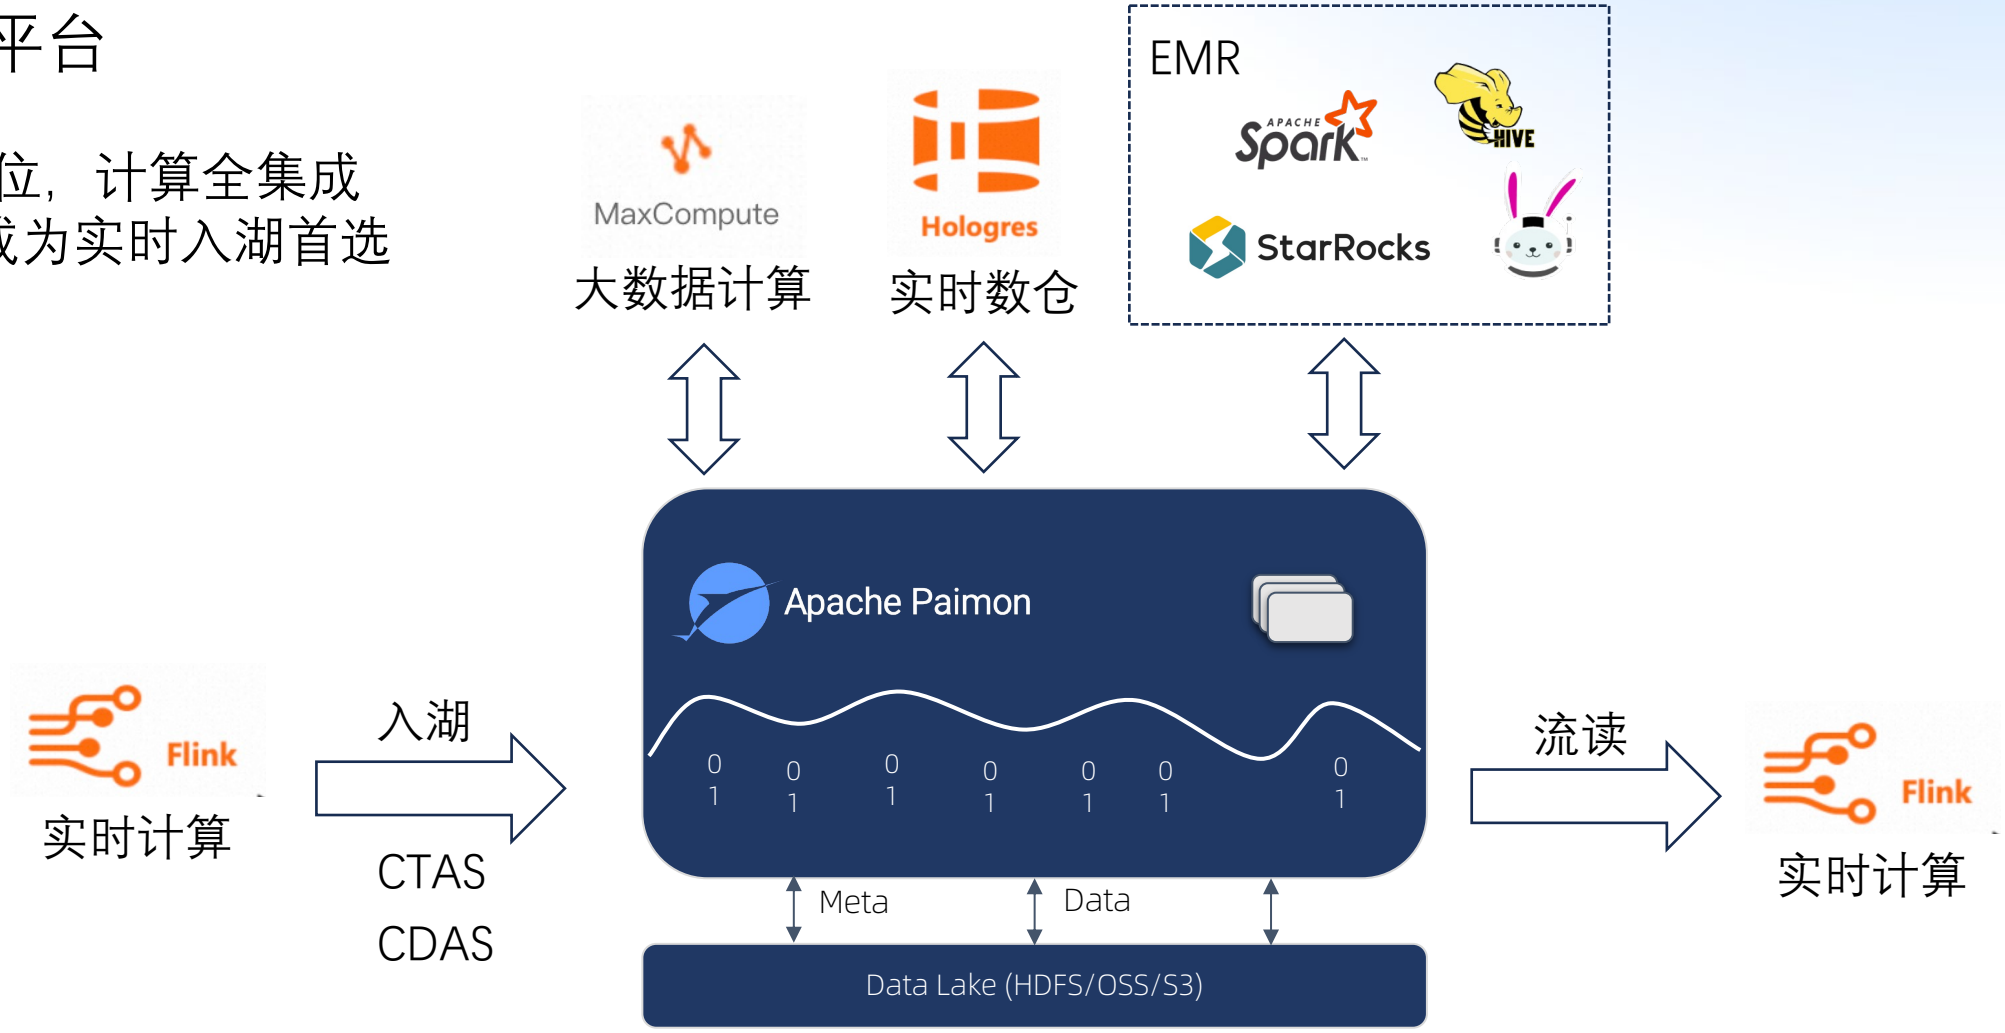

字节跳动

Apache Flink Apache Paimon

血缘管理与一致性查询

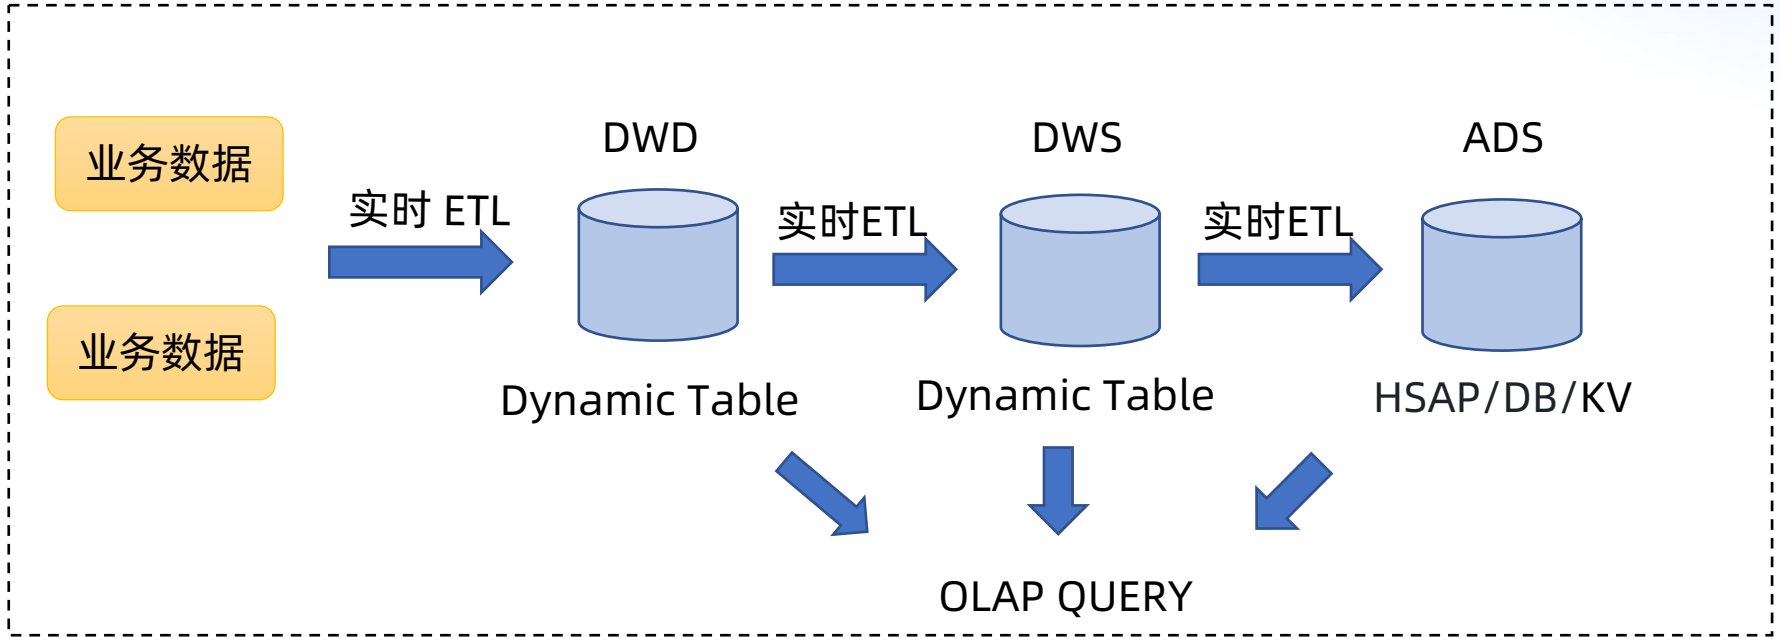

Streaming Warehouse 生产体系

同程旅行

Apache Flink Apache Paimon

引入 Paimon 优化原有 Hudi 近实时数仓

#1

场景1: 实时写入ODS层场景

Paimon任务数量：114+

目前最大Upsert日增量：2000万+

目前最大表总量：90亿+

#2

场景2：局部更新场景

任务数量：10+

真.局部更新优化后会逐步上线

#3

场景3：流读\增量读场景

流式增量读任务数量：20+

批处理小时级增量读：10+

陆续推广替换中

社区的应用

Apache Flink Apache Paimon

- 中原银行：探索流式数仓
- 米哈游：流批一体近实时数仓
- Bilibili：攻坚 AI 方向，Partial-Update
- 尘锋信息：TB级数据入湖，建设Flink流批一体
- 巴别时代：整库入湖，CDC入湖
- 海兰寰宇：替代Kafka作全增量顺序流读
- 汽车之家：Partial-Update宽表拼接

四、后续规划

Streaming LakeHouse

Apache Flink Apache Paimon

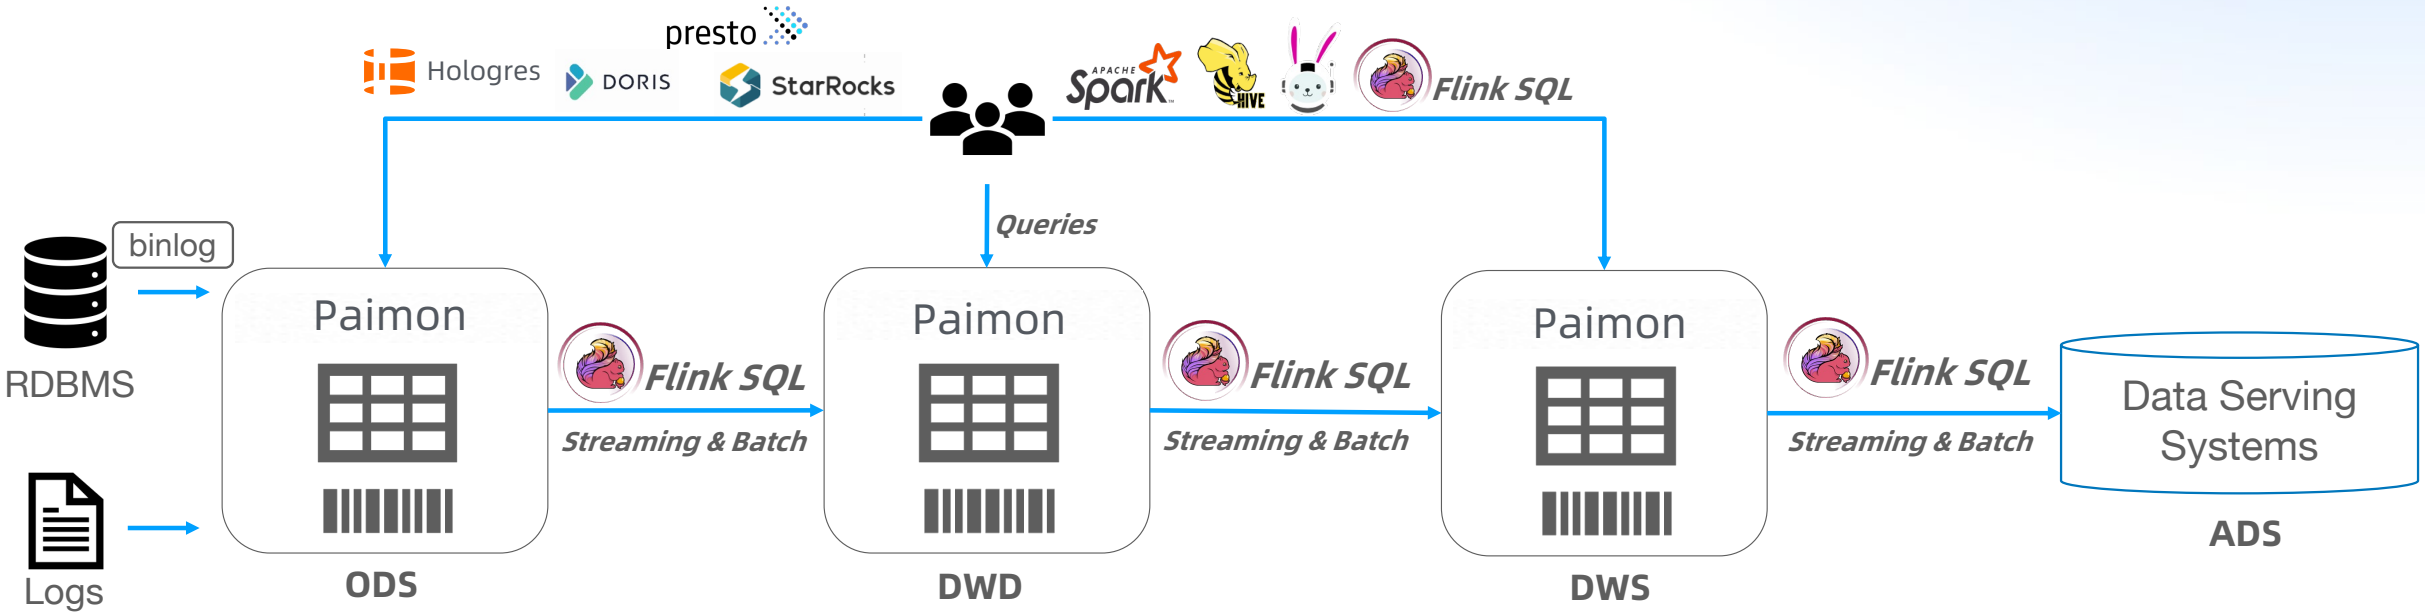

易用的、简单的 Streaming LakeHouse

Apache Flink Apache Paimon

1.更多 CDC 入湖
2.动态 Bucket 全自动
3.Create Tag

Append-Only 处理增强
无 Bucket，小文件合并

Spark 读写增强
Spark 执行过程

发展历程 规划图

Apache Flink Apache Paimon

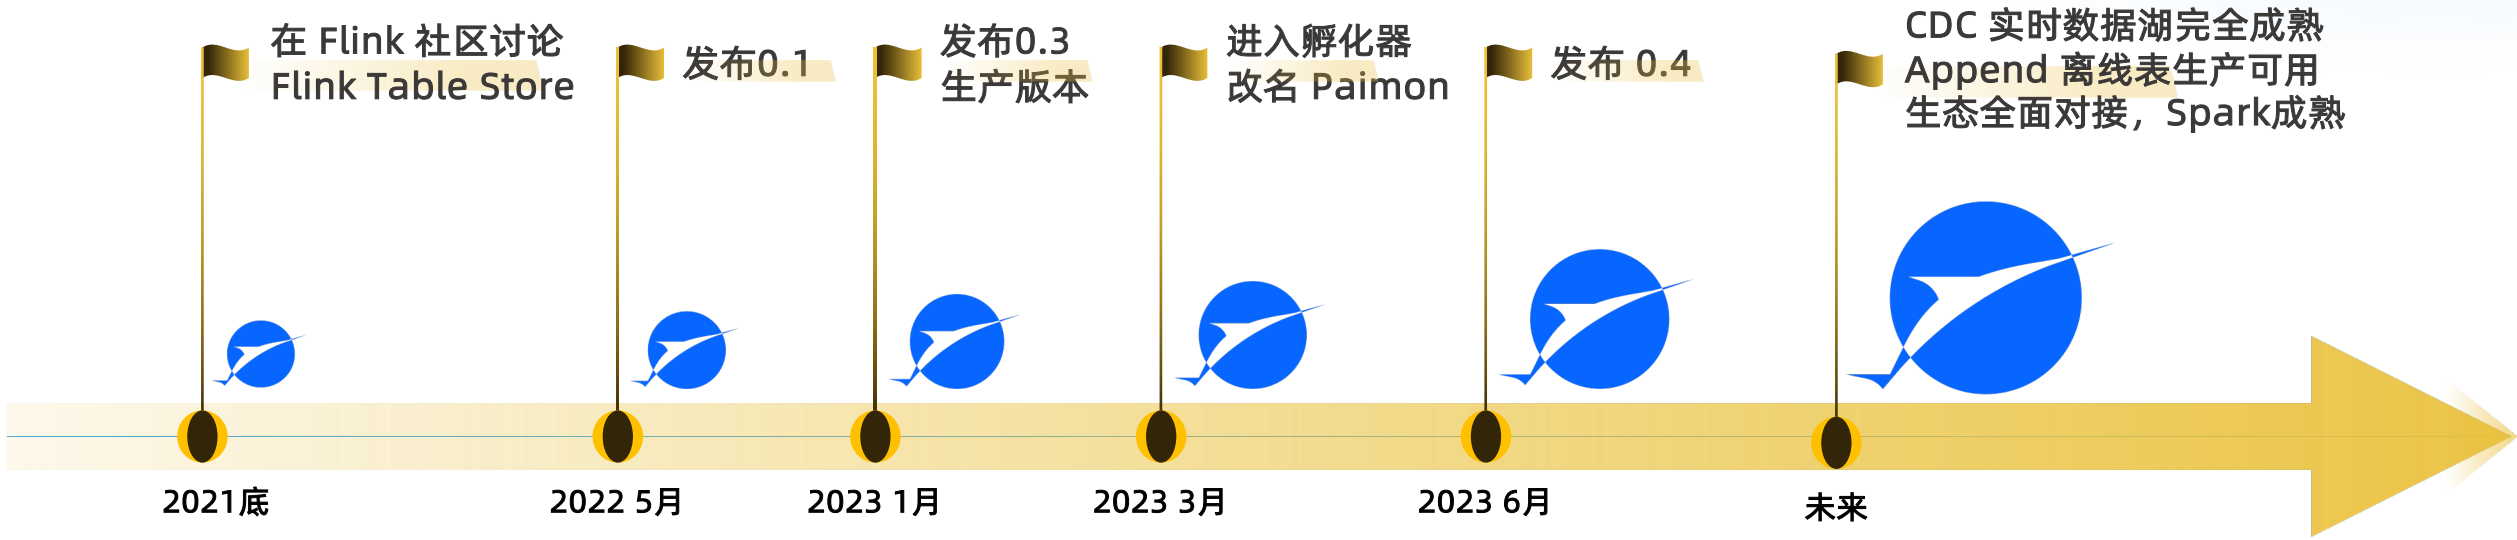

项目信息

Apache Flink Apache Paimon

- Paimon 官网：
  https://paimon.apache.org/
- 微信公众号
  关注：Apache Paimon
- Piamon Github：
  https://github.com/apache/incubator-paimon

Apache Flink Apache Paimon

谢谢！